



湖南大学
HUNAN UNIVERSITY

图算法前沿

湖南大学计算机学院

目录

第一节

链接分析问题

第二节

图查询问题

第三节

社区发现问题

第四节

知识图谱

链接分析内容



什么是链接分析？

- 链接分析也称链接分析法或超链分析，可广义理解为以Web中页面间的超链接为研究对象的分析活动。


涉及的文档

- 四个层面：页面、目录、域名、站点

主要内容

- Web结构研究
- 链接增长规律研究
- 链接分类研究
- 链接分析算法
- 链接分析工具研究

重点：Web链接分析!!!



链接分析应用领域



搜索引擎与网站设计

- 链接分析算法用于对检索结果排序，有效提高检索效率
- 网站根据搜索引擎的原理和排序算法改进网络结构、提高网站质量以增加其可见度




链接分析历史



1978年，Nelson在《Dream Machine》中提到“链接”，指出链接带来了文件连通的可能性，并在1981年描述了全球化大文档想法

1996年，Larson在《Bibliometrics of the World Wide Web: An Exploratory Analysis of the Intellectual Structure of Cyberspace》一文中明确将信息技术从文献计量学移植到网络

1998年，Google的创始人Brin和Page（拉里·佩奇）公开了PageRank算法的核心部分



1995年，Brazilian Marcia J. Bossy首次提出可将信息技术应用于因特网



1997年，Almind和Ingwersen提出了“网络计量学（webometrics）”一词，旨在定量分析网络现象

PageRank




基本思路：链接即投票

- 网页链接数越多越重要
- 入链多少？出链多少？

将指向某网页的导入链作为该网页获得的投票

所有的导入链都是相同的吗？

- 从重要的网页获得的投票应该给予更高权重
- 递归问题！ （多轮投票）



链接即投票



<http://www.alexa.com>

What sites link to hnu.edu.cn?

Total Sites Linking In

331

Site	Page
1. baidu.com	tieba.baidu.com/f?kw=湖南大学
2. sina.com.cn	kaoshi.edu.sina.com.cn/college/c/10532...
3. so.com	baike.so.com/doc/5348407-5583860.html
4. china.com.cn	u.edu.china.com.cn
5. rednet.cn	sk.rednet.cn

What sites link to csu.edu.cn?

Total Sites Linking In

856

Site	Page
1. sina.com.cn	blog.sina.com.cn/kuangcuilin
2. 360.cn	edu.360.cn/daxue
3. stackoverflow.com	stackoverflow.com/users/2374716/sarly
4. pixnet.net	shingi015.pixnet.net/blog/4
5. so.com	baike.so.com/doc/2840941-2998095.html

简单的递归公式




每条链接的投票数正比于其源网页的重要程度

如果重要程度是 r_j 的网页 j 有 n 条出链，那么每条出链拥有 r_j/n 个投票数

网页 j 的重要程度即为其入链投票数之和

$$r_j = r_i/3 + r_k/4$$



递归公式




从重要的网页获得的投票更有价值

被其他重要网页链接的网页也重要

对网页j定义排名 r_j

$$r_j^{(k+1)} = \sum_{i \rightarrow j} \frac{r_i^{(k)}}{deg_i}$$

其中 d_i 是节点 i 的出度



“流”等式:

$$r_y^{(k+1)}$$

$$= r_y^{(k)} / 2 + r_a^{(k)} / 2$$

$$r_a^{(k+1)} = r_y^{(k)} / 2 + r_m^{(k)}$$

$$r_m^{(k+1)} = r_a^{(k)} / 2$$

阻尼系数




有一些网页是dead ends（没有出链），这些网页导致投票被“泄露”；此外，用户很可能不沿着超链接跳转了，而是直接另开一个网页

阻尼系数d 用来表示在PageRank 迭代过程中一个点沿着出边跳转到下一个点的概率。于是， $1 - d$ 表示浏览过程随机跳转到下一个点的概率。于是

$$r_j = \frac{1 - d}{|V|} + d \times \sum_{i \rightarrow j} \frac{r_i}{deg_i}$$

例子: PageRank 分数



目录

第一节

链接分析问题

第二节

图查询问题

第三节

社区发现问题

第四节

知识图谱


子图匹配



给定一个数据图G和一个查询图Q, 找出一个Q在G上的匹配g, 使得

$$\forall v \in V(Q), F(v) = F'(g(v)); \text{ and}$$

$$\forall v_1, v_2 \in V(Q), \overrightarrow{v_1 v_2} \in E(Q) \Rightarrow \overrightarrow{g(v_1)g(v_2)} \in E(G)$$







L. P. Cordella, P. Foggia, C. Sansone, and M. Vento. A (sub) graph isomorphism algorithm for matching large graphs. TPAMI, 26(10):1367–1372, 2004.



找出点对 (u,v) 的集合, 其中 Q 上点 u 在 G 上的匹配是 v



Q



G


S_1	S_2
$(1, 1)$	$(1, 4)$
$(2, 2)$	$(2, 2)$
$(3, 3)$	$(3, 3)$

VF2 Algorithm



根据每个查询点的可能匹配点对，在图上进行搜索得到最终解

如何减少每个查询点可能匹配点对的数目？



Candidate Pair Sets



(2, 2)	(1, 1)	(1, 4)
	(3, 3)	(3, 3)

VF2 Algorithm



一个匹配可以从图中搜索路径中搜索得到，于是可以给查询点定个顺序

Eg. $(1 < 2 < 3)$



基于最坏情况下最优连接的子图匹配



Amine Mhedhbi, Semih Salihoglu: Optimizing Subgraph Queries by
Combining Binary and Worst-Case Optimal Joins. PVLDB 12(11): 1692-
1704 (2019)

Outline




Worst-Case Optimal Joins

Optimizing WCO Plans

Triangle Query



Consider the triangle query, $R(x,y) \bowtie S(y,z) \bowtie T(x,z)$ and let $|R|=|S|=|T|=N$. Then, the size of the query results is at most $N^{1.5}$



Hypergraph



A hypergraph is a pair $H = (V(H), E(H))$, consisting of a nonempty set $V(H)$ of vertices, and a set $E(H)$ of subsets of $V(H)$, the hyperedges of H

Fractional Edge Cover



A fractional edge cover of a hypergraph $H = (V, E)$ is a mapping $f: E \rightarrow [0, \infty)$ such that $\sum_{e \in E, v \in e} f(e) \geq 1$ for all $v \in V$.

The number $\sum_{e \in E} f(e)$ is the weight f . The fractional edge cover number $\rho^*(H)$ of H is the minimum of the weights of all fractional edge covers of H .

Upper Bound of Joins



Given a set of relations for joining, there is a vertex for each attribute of the query and a hyperedge for each relation.


Then, given a fractional edge cover f , we have an upper bound of the query result size $|out|$ as follows

$$|OUT| \leq \prod_{e \in E} |R_e|^{f(e)}$$


Examples for Worst-case Optimal Joins



The following three queries have very different query result sizes



$$|OUT| \leq N^{1.5}$$



$$|OUT| \leq N^3$$



$$|OUT| \leq N^2$$

Generic Join



Generic Join [30] is a worst-case optimal (WCO) join algorithm that evaluates queries one attribute at a time


First, Generic Join picks an order of query vertices to match. It often assume that the subquery induced by the first k query vertices in the order is connected

Second, Generic Join iteratively evaluates one query vertex according to the order

Evaluation Example



Query vertices order $\langle a_2, a_3, a_1, a_4 \rangle$



How to Evaluate Query Vertices in Order



There are two basic operators to evaluate query vertices in order: Scan and Extend/Intersect

Scan: The first two vertices of the order, which match a single query edge, are evaluated by scanning the data graph to find matches of the query edge.

Extend/Intersect



Extend/Intersect: After the subquery induced by the first k query vertices in the order are evaluated, Generic Join extends each match m of k query vertices to one or more matches of $k+1$ query vertices.

The operator first computes the extension set S of m by intersecting the adjacency lists of k query vertices' matches and then extends m to $m \times S$

Outline



Worst-Case Optimal Joins

Optimizing WCO Plans

Effects of Query Vertex Order(QVO)




Directions of Intersected Adjacency Lists

Number of Intermediate Partial Matches

Intersection Cache Hits


Directions of Intersected Adjacency Lists



	BerkStan			Live Journal		
QVO	time	part. m.	i-cost	time	part. m.	i-cost
$a_1 a_2 a_3$	2.6	8M	490M	64.4	69M	13.1B
$a_2 a_3 a_1$	15.2	8M	55,8B	75.2	69M	15.9B
$a_1 a_3 a_2$	31.6	8M	55,9B	79.1	69M	17.3B

Which combination of adjacency list directions is more efficient depends on the structural properties of the input graph, e.g., forward and backward adjacency list distributions.


Number of Intermediate Partial Matches



QVO	Amazon			Epinions		
	time	part. m.	i-cost	time	part. m.	i-cost
$a_1 a_2 a_3 a_4$	0.9	15M	176M	0.9	4M	0.9B
$a_1 a_3 a_2 a_4$	1.4	15M	267M	1.0	4M	0.9B
$a_2 a_3 a_1 a_4$	2.4	15M	267M	1.7	4M	1.0B
$a_1 a_4 a_2 a_3$	4.3	35M	640M	56.5	55M	32.5B
$a_1 a_4 a_3 a_2$	4.6	35M	1.4B	72.0	55M	36.5B

Which QVOs will generate fewer intermediate matches depend on several factors: (i) the structure of the query; (ii) for labeled queries, on the selectivity of the labels on the query; and (3) the structural properties of the input graph, e.g., graphs with low clustering coefficient generate fewer intermediate triangles than those with a high clustering coefficient.

Intersection Cache Hits



	Amazon			Epinions		
QVO	time	part. m.	i-cost	time	part. m.	i-cost
$a_2 a_3 a_1 a_4$	1.0	11M	0.1B	0.9	2M	0.1B
$a_1 a_2 a_3 a_4$	3.0	11M	0.3B	4.0	2M	1.0B

The intersection cache of our E/I operator is utilized more if the QVO extends $(k-1)$ -matches to a_k using adjacency lists with indices from $a_1, \dots, a_{k-2}$.

Cost Metric for WCO Plans



We introduce a new cost metric called intersection cost (i-cost), which we define as the size of adjacency lists that will be accessed and intersected by different WCO plans.

$$\sum_{Q_{k-1} \in Q_2 \dots Q_{m-1}} \sum_{t \in Q_{k-1}} \sum_{\substack{(i, dir) \in A_{k-1} \\ \text{s.t. } (i, dir) \text{ is accessed}}} |t[i].dir|$$

HashJoin Operator



We use the classic hash join operator, which first creates a hash table of all of the tuples of Q_{c1} on the common query vertices between Q_{c1} and Q_{c2} . The table is then probed for each tuple of Q_{c2} .

Dynamic Programming Optimizer



We initialize the cost of computing 2-vertex sub-queries of Q . Then starting from $k = 3$ up to $|V_Q|$, for each k -vertex sub-query Q_k of Q , we find the lowest cost plan $P_{Q_k}^*$ to compute Q_k in three different ways:

- $P_{Q_k}^*$ is the lowest cost WCO plan that we enumerated.
- $P_{Q_k}^*$ extends the best plan $P_{Q_{k-1}}^*$ for a Q_{k-1} by an E/I operator.
- $P_{Q_k}^*$ merges two best plans $P_{Q_{c1}}^*$ and $P_{Q_{c2}}^*$ for Q_{c1} and Q_{c2} , respectively, with a HASH-JOIN.

目录

第一节

链接分析问题

第二节

图查询问题

第三节

社区发现问题

第四节

知识图谱

社区结构




对整个复杂网络的研究一直是许多领域的研究热点，其中社区结构是复杂网络中的一个普遍特征，整个网络是由许多个社区组成的。

设图 $G = G(V, E)$ ，所谓社区发现是指在图 G 中确定 $n_C (\geq 1)$ 个社区

$$C = \{C_1, C_2, \dots, C_{n_C}\}$$

使得各社区的顶点集合构成 V 的一个覆盖

Facebook网络



经典的社区研究案例




a. 空手道俱乐部 (karate club)

b. 科学家合作网络 (Collaboration network)

c. 斑马群体的社交行为研究

其中著名的空手道俱乐部社区已经成为通常检验社区发现算法效果的标准 (benchmark) 之一






M. Girvan, M. E. J. Newman. Community structure in social and biological networks. Proceedings of the National Academy of Sciences of the United States of America. 2002. 99 (12): 7821–7826

GN算法



GN算法是一种分裂型的社区结构发现算法，该算法的基本思想是，根据网络中社区内部高内聚、社区之间低内聚的特点，逐步去除社区之间的边，取得相对内聚的社区结构。即通过不断地移除介数最大的边，将网络逐步分解为不同的社区结构。

如果一条边连接两个社区，那么这两个社区节点之间的最短路径通过该边的次数就会最多，相应的边介数最大。如果删除该边，那么两个社区就会分割开



边介数中心度



具体地，介数中心度的计算公式为：

$$C_B(e) = \sum_{s \neq v \neq t \in V} \frac{\sigma_{st}(e)}{\sigma_{st}}$$

其中， σ_{st} 表示从节点 s 到 t 的最短路径数量， $\sigma_{st}(e)$ 表示其中经过节点 e 的最短路径数量。

边介数中心度




第一步：计算网络中的每条边的边介数；

第二步：删除网络中边介数的值最大的边；

第三步：重新计算网络中所有边的边介数；

第四步：重复执行第二、三步，直到网络中所有边被删除

GN算法结果



GN算法的优劣



优点：全局搜索算法，有很强实用性

缺点：GN算法对于网络中的社区结构没有一个量的定义，因此，它不能直接地从网络中的拓扑结构来判断所划分的社区结构是否是网络中真是存在的社区结构，所以需要一些附加的信息来判断划分的社区结构是否具有实际意义。另外，GN算法还不能判断算法终止位置为了解决这个问题，Newman引入了模块度Q的概念。

Newman快速算法



Newman M E. Fast algorithm for detecting community structure in networks[J]. Physical Review E, 2003.

模块度Q



模块度的定义如下：

模块度指网络中连接社区结构内部节点的边所占的比例与另外一个随机网络中连接社区结构内部节点的边所占比例的期望值相减得到的差值。

一系列推导后得到的公式为：

$$Q = \sum_{c \in C} \left(\frac{I_c}{m} - \frac{D_c^2}{2m} \right)$$

其中 m 为网络中总边数， I_c 为社区 c 中所有内部边的条数， D_c 为社区 c 中所有节点的度之和

Newman快速算法





Newman快速算法不仅解决了GN算法的速度问题，还提出了社区模块度 Q 的概念。

具体算法可描述如下：

- 1) 初始化：将每个节点视作一个社区， Q 初值为0；
- 2) 合并：计算将有边相连的两个社区合并后的 Q 值的增量 ΔQ 选择 ΔQ 最大（或最小）的社区对进行合并；
- 3) 终止条件：重复2)，直到整个网络合并为一个社区

划分结果可以用树状图直观的进行表示出来，最优划分选择 Q 值最大的层次

NF算法用于空手道俱乐部社区划分



目录

第一节

链接分析问题

第二节

图查询问题

第三节

社区发现问题

第四节

知识图谱

知识图谱 (Knowledge Graph)

2012年5月16日，Google发布“知识图谱”的新一代“智能”搜索功能。

Go29gle

瓦特

全部

图片

地图

视频

新闻

更多

设置

工具

找到约 15,700,000 条结果（用时 0.63 秒）

zh.wikipedia.org › zh-hans › 瓦特

瓦特- 维基百科，自由的百科全书

瓦特（符号：W）是国际单位制的功率单位。瓦特的定义是1焦耳/秒（1 J/s），即每秒钟转换，使用或耗散的（以安培为量度的）能量的速率。日常生活中更常用千瓦作为 ...
量级 · 千瓦

baike.baidu.com › item › 瓦特

瓦特（功率单位）_百度百科

瓦特是国际单位制的功率单位。瓦特的定义是1焦耳/秒（1J/s），即每秒转换、使用或耗散的（以焦耳为量度的）能量的速率。在电学单位制中，是伏特乘安培乘功率 ...

baike.baidu.com › item › 瓦特

詹姆斯·瓦特_百度百科

詹姆斯·瓦特（James Watt，1736年1月19日— 1819年8月25日），英国发明家，第一次工业革命的重要人物。1776年制造出第一台有实用价值的蒸汽机。以后又经过一 ...
代表作品: 改良蒸汽机 外文名: James Watt
家世背景 · 改良蒸汽机 · 个人生活 · 人物争议

瓦特

功率单位



瓦特是国际单位制的功率单位。瓦特的定义是1焦耳/秒，即每秒钟转换，使用或耗散的能量的速率。日常生活中更常用千瓦作为单位，1千瓦=1000瓦特，千瓦又可合写作“瓩”。在电学单位制中，瓦特 = 伏特·安培，但不是伏安。瓦特只用来表示交流电的实功率，伏安用来表示视在功率，两者的比为功率因数。单位转换： 电磁学：
维基百科

反馈

查看以下内容的结果：

詹姆斯·瓦特 / 发明家

传统互联网搜索技术

基于关键词字符串匹配

1. 爬取网页建立倒排索引
2. 基于倒排索引，搜索引擎首先找到了包含关键词的网页
3. 根据打分策略（如Pagerank，HITS等），对网页排序
4. 返回用户



计算机并不理解背后的语义

知识图谱的目的

构建知识图谱的目的，就是让机器具备认知能力，理解这个世界。

Baidu

百度

瓦特是哪个学校的校友?

百度一下

网页

资讯

视频

图片

知道

文库

贴吧

采购

地图

更多»

百度为您找到相关结果约359,000个

搜索工具

瓦特是哪个大学毕业的_百度知道

2个回答 · 回答时间: 2016年12月1日

最佳答案: 瓦特没受过正规的大学教育。 瓦特的求学经历: 1757年,格拉斯哥大学的教授提供给瓦特一个机会,让他在大学里开设了一间小修理店,这帮助瓦特...

更多关于瓦特是哪个学校的校友?的问题>>

百度知道 - 百度快照

瓦特是以什么身份迈进大学的校门的?_百度知道

1个回答 · 回答时间: 2020年1月2日

最佳答案: 像瓦特这样的人才正是当时的格拉斯哥大学所紧缺的,再加上迪克博士和学校教授们的帮助,学校当局终于同意在校园里给瓦特一个工作间,并且授予了他一个"大学..."

更多关于瓦特是哪个学校的校友?的问题>>

百度知道 - 百度快照

瓦特?据说这是最难毕业的学校!_博洛尼亚



2018年12月19日 - 这座城市也因其欧洲著名学术中心的地位闻名于世——天文望远镜的发明者伽利略和以花心浪荡出名的卡萨诺瓦都是这所学校的校友。帕多瓦大学建立于1222年,当年...

搜狐网 - 百度快照

厉害了,进了这个英国名校,你就是亚当斯密的校友了!



2018年3月5日 - 1870年以后,格拉斯哥大学从市中心搬到了西区(West End),学校规模不断扩大,逐渐...瓦特成名后,格拉斯哥大学授予他法学名誉博士学位,属于“编外”校友。 图片9:格大...

搜狐网 - 百度快照

瓦特是哪个学校的校友?

格拉斯哥大学_百度百科

格拉斯哥大学 (University of Glasgow)，简称格大，始建于1451年，位于英国苏格兰最大城市**格拉斯哥市**，世界百强名校，英国顶尖学府，全球最古老的十所**大学**之一，英语世界国家第四古老的**大学**。格大同时也是英国罗素**大学**集团和Universitas 2...

[历史发展](#) [学校排名](#) [地理交通](#) [学院介绍](#) [学校建筑](#) [更多>>](#)

<https://baike.baidu.com/>

知识图谱 (Knowledge Graph)

什么是知识图谱?

知识图谱本质上是基于图的语义网络，表示实体和实体之间的关系！

詹姆斯·瓦特 (1736年1月19日 — 1819年8月25日) 英国发明家，出生于苏格兰的港口小镇格林诺克，第一次工业革命的重要人物。他于1776年制造出第一台有实用价值的蒸汽机，进而开辟了人类利用能源新时代，使人类进入“蒸汽时代”……


格拉斯哥大学 英国老牌名校，位于苏格兰的格拉斯哥市，始建于1451年，是全球最为古老的十所大学之一，英语世界国家第四古老大学。作为一所英国综合性古典大学，格拉斯哥大学与人类文明的发展紧密相联。经济学之父亚当·斯密、工业革命之父詹姆斯·瓦特等大批杰出校友均为社会的发展进步做出了举世瞩目的贡献。
……

抽取

抽取的实体：
詹姆斯·瓦特
苏格兰
格林诺克
蒸汽机
格拉斯哥大学
苏格兰
亚当·斯密

抽取的关系：
出身于
制造
位于
校友
……

构建




知识图谱 (Knowledge Graph)




工业应用





BioModels, Biosamples, ChEMBL, Ensembl, Atlas, Reactome and UniProt

Facebook Social Graph



The screenshot shows the Facebook for developers website. The top navigation bar includes links for Products, Docs, Tools & Support, News, and Videos, along with a search bar and a Register button. The left sidebar contains a list of documentation topics under the heading 'Graph API'. The main content area is titled 'The Basics' and explains the concept of the Graph API as a 'social graph' representing information on Facebook. It lists three key components: nodes, edges, and fields, each with a brief description. The text concludes by stating that the Graph API is HTTP based and can be used directly in a browser.

facebook for developers

Products Docs Tools & Support News Videos

Search Register

All Docs

Graph API

- Overview
- Using the Graph API
- Reference
- Common Scenarios
- Other APIs
- Advanced
- Changelog

Docs / Graph API / Overview / On this page: ▼

The Basics

The Graph API is named after the idea of a 'social graph' - a representation of the information on Facebook composed of:



- **nodes** - basically "things" such as a User, a Photo, a Page, a Comment
- **edges** - the connections between those "things", such as a Page's Photos, or a Photo's Comments
- **fields** - info about those "things", such as a person's birthday, or the name of a Page

The Graph API is HTTP based, so it works with any language that has an HTTP library, such as cURL, urllib. We'll explain a bit more about what you can do with this in the section below, but it means you can also use the Graph API directly in your browser, for example a [Graph API request](#) is equivalent to:

Facebook Social Graph

2013年1月16日 Facebook Graph Search 产品发布会
——Mark Zuckerberg

“My friends who live in Canada”



Facebook Social Graph

“Photos of my friends who live in Canada”



知识图谱数据模型

RDF (Resource Description Framework)

RDF定义了一个简单的模型，用于描述资源，属性和值之间的关系。资源是可以用URI标识的所有事物，属性是资源的一个特定的方面或特征，值可以是另一个资源，也可以是字符串。总的来说，一个RDF描述就是一个三元组：<主语、谓词、宾语>。

□ 用列表表示的RDF示例：

Subject	Predicate	Object
http://w3.org/	created_by	#anonymous
# anonymous	name	"John"
# anonymous	phone	"477738"

知识图谱数据模型

□ RDF (Resource Description Framework)


主体	属性	客体
dbr:James_Watt	rdfs:label	"James Watt"@en
dbr:James_Watt	dbo:birthDate	"1736-01-19"^^xsd:date
dbr:James_Watt	dbo:birthPlace	dbr:Greenock
dbr:James_Watt	rdf:type	dbo:Scientist
dbr:James_Watt	dbo:influencedBy	dbr:Joseph_Black
dbr:James_Watt	dbo:influencedBy	dbr:Adam_Smith
dbr:James_Watt	dbp:workplaces	dbr:University_of_Glasgow
dbr:Adam_Smith	rdfs:label	"Adam Smith"@en
dbr:Adam_Smith	dbo:birthDate	"1723-06-16"^^xsd:date
dbr:Adam_Smith	dbo:almaMater	dbr:University_of_Glasgow
dbr:Adam_Smith	dbo:influencedBy	dbr:Aristotle
dbr:Joseph_Black	rdfs:label	"Joseph Black"@en
dbr:University_of_Glasgow	name	"University Of Glasgow"@en
dbr:Aristotle	rdfs:label	"Aristotle"@en
dbr:Aristotle	dbo:birthDate	"-383-1-1"^^xsd:date
dbr:Greenock	dbo:country	dbr:United_Kingdom
dbr:Greenock	dbo:type	dbo:Place
dbr:United_Kingdom	dbo:type	dbo:Place
dbo:Scientist	dbo:subClassOf	dbo:Person
dbo:Person	dbo:subClassOf	dbo:Agent

知识图谱数据模型

RDF (Resource Description Framework)

RDF定义了一个简单的模型，用于描述资源，属性和值之间的关系。资源是可以用URI标识的所有事物，属性是资源的一个特定的方面或特征，值可以是另一个资源，也可以是字符串。总的来说，一个RDF描述就是一个三元组：<主语、谓词、宾语>。


□ 用有向图表示的RDF示例：



知识图谱数据模型

□ RDF (Resource Description Framework)


RDF所表示的瓦特知识图谱



知识图谱数据模型

□ RDF (Resource Description Framework)

在RDF数据层的基础上引入模式层，定义类、属性、关系、属性的定义域与值域来描述与约束资源，构建最基本的类层次体系和属性体系，支持简单的上下位推理。



大规模知识图谱

Yago(Yet Another Great Ontology)

2007年，由德国马普研究所发起
融合WordNet和Wikipedia:

- 从Wikipedia的结构中抽取信息
- 利用人工采样评估
- 超过1亿事实和100种关系



Content	Entities of public Interest
Format	TSV ,RDF ,XML ,N3 ,Web Interface
Sources	Wikipedia , WordNet , Geonames
Main Strength	Focus on Precision , geotemporal annotations ,multilingual
Precision	95%
Technique	Extraction from Wikipedia + matching with WordNet & Geonames + consistency checks
Size	Entities: 3 m (+ geonames → 10m) Facts: 120m (+ geonames → 460m) Relations: 100 , Classes: 200k , Languages: 200
License	Creative Commons BY-SA
URL	http://www.yago.com/
References	[Suchanek , WWW 2007][Hoffart , WWW 2011] [deMelo CIKM 2010]

大规模知识图谱

DBPedia

2007年开放。

目标是构建一个社区，通过社区成员定义和撰写准确的抽取模板，进而从维基百科中抽取结构信息，并将其发布到Web上。

社区通过人工的方式构建分类：

- 280个类别
- 覆盖约50%的维基百科实体



Content	Entities of public Interest
Format	RDF, API, SPARQL
Sources	Wikipedia, WordNet, YAGO
Main Strength	Focus on coberage, interlinking with other data sets
Technique	Extraction from Wikipedia +manual supervision by the community
Size	Entities: 3.5 m (in manual taxonomy: 1.7m) Facts: 670m Attributes: 9k (manually defines: 1k) Manual Classes: 280
License	CC-BY-SA & GNU FDL
URL	http://dbpedia.org
References	[Auer, ISWC 2007], [Bizer09, JWS 2009]]

大规模知识图谱

Freebase

2007年Metaweb公司发布。

2010年被Google收购。

大规模协同构建知识库。

从Wikipedia和其他数据源(如 IMDB、MusicBrainz

中导入知识

核心思想:

- 在Wikipedia中, 人们编辑文章
- 在Freebase中, 人们编辑结构化知识

Content	Entities of public Information
Format	RDF, API
Construction	By the community Data import from public sources
Sources	Wikipedia, Libraries, WordNet, MusicBrainz...
Main Strength	Free and large
Size	Facts: several: millions Entities: 20m
License	CC-BY(Creative Commons Attribution)
URL	http://www.freebase.be/



知识图谱的语义搜索

语义搜索

- 是指搜索引擎的工作不再拘泥于用户所输入请求语句的字面本身，而是透过现象看本质，准确地捕捉到用户所输入语句后面的真正意图，并以此来进行搜索，从而更准确地向用户返回最符合其需求的搜索结果。

语义搜索过程

输入的问句进行解析，找出问句中的实体和关系，理解用户问句的含义，

将用户在知识图谱中匹配查询语句，找出答案

通过一定的形式将结果呈现到用户面前

The screenshot shows a Google search interface. The search bar contains the query '莱昂纳多是什么时候出生的?' (When was Leonardo born?). The search results show approximately 3,160,000 results. A detailed profile card for Leonardo DiCaprio is displayed, showing his birth date as '1974年11月11日 (44岁)' (November 11, 1974 (44 years old)). The card also includes a photo of him, a list of other searches (e.g., '凯特·温斯莱特', '布拉德·皮特'), and a list of awards and movies. The profile card is titled '莱昂纳多·迪卡普里奥' (Leonardo DiCaprio) and lists his profession as '演员' (Actor).

莱昂纳多·迪卡普里奥 / 出生日期

1974 年 11 月 11 日 (44 岁)

用户还搜索了

凯特·温斯莱特 1975 年 10 月 5 日

布拉德·皮特 1963 年 12 月 18 日

约翰尼·德普 1963 年 6 月 9 日

莱昂纳多·迪卡普里奥_百度百科

https://baike.baidu.com/item/莱昂纳多·迪卡普里奥

莱昂纳多·迪卡普里奥 (Leonardo DiCaprio), 1974年11月11日出生于美国加利福尼亚州洛杉矶。美国... 2010年的《禁闭岛》是莱昂纳多和马丁·斯科塞斯的第四次合作。... 莱昂纳多一出生，他的父母便已

莱昂纳多·迪卡普里奥

演员

莱昂纳多·威廉·迪卡普里奥是一位美国著名男演员、电影制片人兼环保概念的推动者。迪卡普里奥于1990年代开始拍广告，展开职业生涯。随后，他出演了《圣巴巴拉》及《成长的烦恼》等电视剧。1991年，迪卡普里奥出演了他的电影处女作《魔精3》。1993年，他在《这个男孩的生活》及《不一样的天空》中担任主演，并获得不错的评价。 维基百科

生于：1974 年 11 月 11 日 (44 岁)，加利福尼亚州洛杉矶好莱坞

身高：6' 0"

所获奖项： 奥斯卡最佳男主角奖， 美国演员工会奖最佳男主角， 更多

即将上映的电影： 好莱坞往事

家长： 乔治·迪卡普里奥， 艾莫琳·英登比尔肯

提名： 奥斯卡最佳影片奖， 奥斯卡最佳男配角奖， 更多

电影

还有45+项

知识图谱的知识问答

智能问答的方法

1.基于信息检索的方法



- 首先利用中文分词、命名实体识别等自然语言处理工具找到问句中所涉及到的实体和关键词，然后去知识资源库中去进行检索，并通过打分模型对答案进行排序

2.基于语义解析的方法


- 将一个自然语言形式的问句，按照特定语言的语法规则，解析成语义表达式，将其转化为某种数据库的查询语言

知识图谱的知识问答

知识图谱问答的两种主要方法框架对比



医疗领域知识图谱



医疗知识图谱的主要应用


- 智能问诊/分诊服务
- 智能影像辅助诊断
- 智能疾病辅助诊疗
- 精准用药推荐
- 智能患者教育/ 随访
- 智能临床科研平台
- ...

难点：非结构化的电子病历理解成本大

高血压知识图谱示例


医疗领域知识图谱

❖ 医疗知识图谱构建流程



医疗领域知识图谱


❖ 医疗知识图谱Schema



医疗领域知识图谱

智能问诊服务—疾病健康问答

- 定义：基于患者在慢病管理当中会有各种疑问，大量健康教育等相关问题，从医疗知识库当中找到答案并输出
- 举例：糖尿病患者应该如何饮食？立普妥和络活喜可以一起吃吗？空腹血糖8.6，有问题吗？






大模型时代知识图谱新发展

大语言模型简介

神经网络


神经网络由大量相互连接的节点（神经元）组成，这些节点通过加权连接传递信号，能够从数据中学习并执行分类、回归等任务。



大语言模型简介

神经网络



神经网络由大量相互连接的节点（神经元）组成，这些节点通过加权连接传递信号，能够从数据中学习并执行分类、回归等任务。



大语言模型简介

神经网络


神经网络由大量相互连接的节点（神经元）组成，这些节点通过加权连接传递信号，能够从数据中学习并执行分类、回归等任务。



大语言模型简介

大模型概念


在实践领域，神经网络模型往往由数量庞大的神经元构成，这些神经元被精心编排成一系列层级结构。因此，此类模型可能涉及到的参数数量极为庞大。**所谓的大模型，便是指那些拥有海量参数的神经网络模型。**



大语言模型简介

大语言模型概念




所谓的大语言模型，便是指那些面向自然语言处理的拥有海量参数的神经网络模型。实际中，市面上的大语言模型，主要面向的自然语言任务是**语言生成**，也就是根据目前的上文来推断下文



大语言模型的数据工程——涌现


涌现能力

涌现能力是指模型在训练过程中突然展现出之前小模型所没有的、更深层次的复杂特性和能力。当模型的训练数据突破一定规模时，模型能够综合分析和解决更深层次的问题，展现出类似人类的思维 and 智能。这种涌现能力是大模型最显著的特点之一，也是其超越传统模型的关键所在



大语言模型的数据工程——摸索

An Example Of Grokking: Memorization Followed By Sudden Generalization



影响学习速度的数据因素——格式

Data Formatting

Plain

128+367=495

Reverse

\$128+367=594\$

Simplified Scratchpad

Input: 128+367

Target:

A->5, C->1

A->9, C->0

A->4, C->0.

495

Detailed Scratchpad

Input:

128+367

Target:

<scratch>

[1,2,8] has 3 digits.

[3,6,7] has 3 digits.

[1,2,8] + [3,6,7], C=0, 8+7+0=15, A->5, C->1


[1,2] + [3, 6], A= [5], 2+6+1=9, A->9, C->0

[1] + [3], A= [9,5], C=0, 1+3+0=4, A->4, C->0

[] + [], A= [4,9,5], C=0, END

</scratch>



4 9 5



思维链数据越详细，模型学习的速度就越快

影响学习速度的数据因素——数据课程

数据课程



数据课程（Data Curriculum）强调数据之间的依赖关系，在训练大语言模型时，模型学习不同领域知识的速度受到训练数据选择和输入顺序的影响。根据任务的特点，某些知识的学习可能需要前置知识的支持，这时采用“有序输入”策略，即先学习与基础知识相关的数据，再学习后续知识所需的数据。


- ❑ 相较于将不同知识的数据混合训练，按顺序输入知识相关数据能够加快模型对复杂知识的掌握
- ❑ 这种顺序安排不仅有助于模型快速适应不同任务，还能在有限的计算资源下，最大化模型的学习效果

影响学习速度的数据因素——混合比例

LLaMA的数据混合比

Dataset	Sampling prop.	Epochs	Disk size
CommonCrawl	67.0%	1.10	3.3 TB
C4	15.0%	1.06	783 GB
Github	4.5%	0.64	328 GB
Wikipedia	4.5%	2.45	83 GB
Books	4.5%	2.23	85 GB
ArXiv	2.5%	1.06	92 GB
StackExchange	2.0%	1.03	78 GB


在 LLaMA 数据混合比中降低 Github 和 StackExchange 等代码数据的权重，以及 Arxiv等纸质数据的权重，它的编码能力和科学推理能力显著下降。



高效的多模态学习框架 DoReMi 的论文中也表明，更好的数据混合比例可以通过更高的学习曲线提高模型的性能，使模型更快地从数据中学习。

大语言模型微调数据混合比例


微调数据最佳混合比例



当对一个垂直领域进行继续预训练完后，大模型的通用能力会被遗忘，为此惯用的技巧是**混一些通用能力+领域内的数据**一起训练，这样的话既能学习新领域知识又能维持住通用能力

- 最佳混合比例是存在的且是可以被预测的
- 领域loss随着训练是一直下降的，但是通用领域的loss是先保持不变然后开始下降
- 可训练的数据量以及模型规模和最佳混合比例都是呈现正相关的，比如更大的模型通常可以容纳更高的混合比例(当模型足够大数据足够多，那么理论上最佳混合比例可以是1)，当拥有的domain数据量不是那么多的时候，最佳混合比例要低一些。

RAG——知识增强检索



大模型的局限

大模型（如ChatGPT）擅长生成答案，当面对复杂查询或高精度信息时，需要借助外部知识


知识增强检索

结合信息检索与生成式模型，通过从知识数据库中检索相关内容，增强生成答案的准确性与丰富性。

RAG——知识增强检索

数据准备阶段

数据准备一般是一个离线的过程，主要是将私域数据向量化后构建索引并存入数据库的过程主要包括：**数据提取**、**文本分割**、**向量化**、**数据入库**等环节。




RAG——知识增强检索

数据检索阶段

根据用户的提问，通过高效的检索方法，召回与提问最相关的若干文档或信息片段。


常见的数据检索方法包括：**相似性检索（余弦相似性、欧氏距离）**、**全文检索**等



RAG——知识增强检索

生成阶段

将检索到的信息作为上下文或辅助信息，融入到提示词中，大模型参考当前提问和相关知识，生成相应的答案。



基于知识图谱的RAG

(a) Language Model Prompting w/o Knowledge Augmentation

[Prompt]

Question: Which member of Black Eyed Peas appeared in Poseidon?


Answer:

[Generated Answer]

Tariq Ali

(b) Knowledge-Augmented Language Model Prompting

Knowledge Graph



[Prompt]

Below are the facts that might be relevant to answer the question: (Black Eyed Peas, has part, Fergie), (Black Eyed Peas, has part, Kim Hill), (Poseidon, cast member, Fergie)

Question: Which member of Black Eyed Peas appeared in Poseidon?

Answer:

[Generated Answer]

Fergie

实体链接

- 利用现有Refind实体链接器

获取实体相关的一跳三元组

- 直接图上搜索

将三元组转为字符串

- 直接拼接三元组

挑选前k个相关三元组

- 通过现有句子嵌入模型计算语义相似度

结合三元组信息回答


- 直接拼接三元组

基于不完整知识图谱的思考—搜索—生成框架

□ 对于下述问题而言，右侧的知识图谱是不完整的，因为无法生成最合适的三元组路径

Question: What is the time zone of the area where Apple headquarters is located?


Gold Relation Path: *AppleInc* $\xrightarrow{\text{headquarter}}$ *Cupertino* $\xrightarrow{\text{timezone}}$ *Pacific Standard Time*



基于不完整知识图谱的思考-搜索-生成框架


□ **思考-搜索-生成框架：** 整个过程通过反复调用大模型（其实就是 React）来生成和迭代思考（Thought）

1. 首先，基于输入问题生成第一个思考
2. 接着，使用预定义的 SPARQL 查询从知识图谱中提取相关三元组作为观察（Observation）。这些三元组作为提示，继续生成新的思考。每次迭代都在前一个思考和最新观察的基础上深化理解
3. 此过程不断重复，逐步逼近问题核心，直到找到解决方案或确定问题无法解决。



基于不完整知识图谱的思考-搜索-生成框架

□ 如果大模型判断问题无法解决：基于之前的观察，我们首先使用 BM25 算法找到更多相关三元组。接着，利用大模型生成一些原本知识图谱中不存在的新三元组。这些新生成的三元组作为提示，进一步指导模型生成新的思考或答案。





湖南大学
HUNAN UNIVERSITY

谢谢观赏

—— 实事求是 敢为人先 ——